

# 高光谱与多光谱融合超分的多头注意力机制

## 摘要

考虑到光学成像的局限性，图像采集设备通常被设计为在空间信息和光谱信息之间进行权衡。高光谱图像（HSI）由于其丰富的光谱信息，能够精细识别和分类成像对象，而多光谱图像（MSI）则由于其足够的空间信息，能够提供精细的几何特征。因此，将 HSI 和 MSI 进行融合以实现信息互补已成为一种普遍的方式，从而提高了获得信息的可靠性和准确性。然而，与传统的光学多焦点图像融合和 MSI 的全色锐化不同，现有的 HSI 和 MSI 融合方法仍然面临在实现跨模态信息交互和缺乏有效利用空间位置信息方面的问题。为了解决上述问题并实现 HSI 和 MSI 之间更有效的信息集成，本文提出了一种新颖的高光谱和多光谱图像融合的多层次交叉变换器（MCT-Net）。所提出的 MCT-Net 包括两个组件：（1）多层次跨模态交互模块（MCIM），该模块首先提取 HSI 和 MSI 的深度多尺度特征，然后通过应用多层次交叉变换器（MCT）在相同尺度上执行它们之间的跨模态信息交互，以重建 MSI 中缺失的光谱信息和 HSI 中缺失的空间信息；（2）特征聚合重建模块（FARM），该模块结合了来自 MCIM 的特征，使用条带卷积进一步恢复边缘特征，并通过级联上采样来重建融合结果。我们在五个主流 HSI 数据集上进行了比较实验，以证明所提方法的有效性和优越性，包括 Pavia Center、Pavia University、Urban、Botswana 和 Washington DC Mall。例如，在 Washington DC Mall 数据集上，与比较算法中的最先进方法相比，我们的方法提高了 PSNR 达 18.52%。同时将 RMSE、ERGAS 和 SAM 分别减少了 56.63%、56.90% 和 58.58%。我基本复现了该论文中实验结果，并在原来文章的基础上，加入了 Indian、MUUFL\_HSI、Salinas\_corrected、Houston\_HSI 四个数据集，让 MCT 在这些数据集上运行得到结果。并且在复现论文的基础上，加入了 SSIM 的评价指标，使得文章的评价体系更加的完善和多方面。

**关键词：**Transformer 高光谱多光谱图像融合深度多尺度特征

## 1 引言

选题背景：高光谱图像（HSI）和多光谱图像（MSI）在遥感图像处理中发挥着关键作用。HSI 以其数百个连续狭窄的光谱波段，能够准确描述物质的光谱差异，而 MSI 则具有高空间分辨率和低光谱分辨率 [1]。这两者在地物分类、目标检测、频带选择和变化检测等任务中都有广泛应用。然而，由于成像平台的限制，获取高光谱和高空间分辨率的图像（HR-HSI）是一项具有挑战性的任务 [3]。在图像融合领域，传统的方法包括全色锐化和子空间融合，以提高图像的光谱和空间分辨率。然而，这些方法在处理 HSI 和 MSI 的融合时面临一些问题，例如在全色锐化方法中，缺乏跨模态信息交互，而子空间融合方法则依赖于人工设计的融合规则，

缺乏通用性 [5]。深度学习方法因其强大的特征提取能力而在 HSI 和 MSI 融合中表现出潜力，但现有的 CNN-based 方法在提取空间信息和处理全局上下文信息方面仍有一些不足 [10]。

选题依据：本选题基于对现有融合方法的不足之处的认识，特别是在跨模态信息交互和全局上下文建模方面的不足。传统方法和现有深度学习方法在某些情境下难以充分利用空间和光谱信息，导致融合效果不尽如人意 [8]。因此，需要一种新的方法来解决这些问题，并提高 HSI 和 MSI 融合的性能。而通过复现这篇论文，可以为我们寻找解决方案提供一些有用的思路，加深对 HSI 和 MSI 融合的认识。

选题意义提出的多层次交叉变换器 (MCT-Net) 方法旨在克服现有方法的局限性，通过引入 Transformer 的思想，实现了对跨模态信息的更好整合和对全局上下文的更好建模。MCT-Net 利用多层次跨模态交互模块 (MCIM) 和特征聚合重建模块 (FARM) 来充分保留空间-光谱信息，旨在提高 HR-HSI 的质量。通过与现有算法的比较实验，我们可以评估 MCT-Net 在不同 HSI 数据集上的性能，证明其在图像质量改善方面的优越性。这对于提高遥感图像处理的精度和应用广泛性具有重要意义。这也是我选择复现这篇论文的目的，通过对这篇论文的复现以及创新优化，找到在提高 HR-HSI 的质量领域上比较有效的方案，并加以实现。

## 2 相关工作

在本节中，所复现的论文首先介绍了一些现有代表性的多光谱图像 (MSI) 和高光谱图像 (HSI) 融合方法。然后，介绍了 Transformer 在计算机视觉领域的应用概述。

### 2.1 高光谱和多光谱图像融合

近年来，传统方法在 HSI 和 MSI 融合领域取得了许多进展，主要分为基于全色锐化和基于子空间的融合方法。

基于全色锐化的方法是将全色锐化技术应用于 HSI 和 MSI 融合任务。例如，Grohnfeldt 等人提出了一种基于稀疏表示 (SR) 的全色锐化方法，适用于 MSI 波段较少时取得良好结果 [4]。然而，当 MSI 波段较多时，由于 MSI 缺失波段与高分辨率图像的相关性较低，全色锐化方法的效果并不理想。

基于子空间的融合方法通过一组基向量或底层材料的光谱特征将原始图像映射到低维子空间，以实现降维并获得出色性能 [9]。经典的矩阵分解算法将 3D HSI (宽度、高度和光谱波段维度) 扩展为 2D 矩阵，然后通过 LR-HSI 和 HR-MSI 估计的端元矩阵和丰度矩阵重建 HR-HSI [6]。CNMF 是基于非负矩阵分解的方法，通过将 HR-MSI 和 LR-HSI 分解为混合像素，使用 LR-HSI 的丰度矩阵和 HR-MSI 的端元矩阵重建高质量的 HR-HSI [7]。Lanaras 等人通过将两个输入图像解混为观测材料的纯反射光谱和相关混合系数来改善光谱解混，从而提高了融合图像的质量 [2]。这一思想为后来许多 HSI 和 MSI 融合方法的发展提供了主要灵感。

### 2.2 视觉变换器

Transformer 最初由 Vaswani 等人应用于机器翻译，其结构包括编码器和解码器。多头注意力机制可解决长距离依赖问题，并捕捉任意位置之间的关系。Transformer 完全摒弃了卷积，最近在各种计算机视觉任务 (如图像分类、目标检测、图像分割等) 中取得了良好的性

能。Swin Transformer 是一种分层架构，其表示是通过移动窗口计算的，适用于各种视觉任务。Carion 等人提出了一种基于 Transformer 的目标检测算法 (DETR)，将检测视为一种集合预测任务。此外，TransUNet 结合了 Transformer 和 U-Net 的优势，在医学图像分割中取得了显著成就。其他工作也证明了 Transformer 在不同下游任务中的潜力。鉴于 Transformer 在视觉任务中的出色表现，我们尝试将其应用于 HSI 和 MSI 的融合，充分发挥其对建模长距离依赖性的能力。在 HSI 和 MSI 融合中，局部和全局信息同等重要，因此，相较于更注重局部关系的卷积，Transformer 具有更大的潜力。此外，如何在 HSI 和 MSI 之间实现有效的交互整合一直是这一任务中的难点，可能是设计高性能 HSI 和 MSI 融合算法的制约因素。在这项工作中，我们没有仅从一幅图像中提取特征信息，而是采用了更适用于 HSI 和 MSI 融合的设计理念。我们进一步提出了 MCT，它在 Transformer 解决方案的基础上实现了 HSI 和 MSI 之间的交叉关注操作，以提供更高的性能改进。

### 3 本文方法

#### 3.1 本文方法概述

提出的 MCT-Net 的总体架构如图 1 所示。MCT-Net 包括两个主要组件，分别是多层次交互模块 (MCIM) 和特征聚合重构模块 (FARM)。

在 MCIM 中，LR-HSI 和 HR-MSI 通过线性插值和卷积运算进行上采样和下采样，以分别提取低层次详细特征中包含的空间信息和高层次语义特征中包含的语义信息。MCT 用于全局特征提取和信息交互，同时在相同尺度上对特征图进行融合。

在 FARM 中，设计了一种多层次特征融合策略。在这里，不同尺度的提取特征被组合在一起，通过反复堆叠上采样层和带状卷积操作，逐步重构 HR-HSI。

LR-HSI 和 HR-MSI 具有不同的特性。由于 LR-HSI 具有较高的光谱分辨率，其具有更丰富的光谱信息。HR-MSI 由于其较高的空间分辨率，具有更丰富的空间细节。与自然图像相比，遥感图像具有更大的尺度范围。大尺度特征图通常覆盖大面积的建筑轮廓，而小尺度特征图通常包含局部遥感目标的纹理和细节。为了充分提取 HSI 中的光谱信息和 MSI 中的空间信息，我们首先使用双分支结构对 HR-MSI 和 LR-HSI 进行上采样和下采样，以从不同尺度和不同模态中进行特征提取。

对于输入图像  $HR-MSI \in R^{H \times W \times c}$ ， $LR-HSI \in R^{h \times w \times C}$ ，首先对 LR-HSI 进行  $\times 4$  上采样 (使用双线性插值)，以获得与 HR-MSI 相同空间分辨率的  $LR0 \in R^{H \times W \times C}$ 。由于 Transformer 的计算复杂性与序列长度呈二次关系，直接将输入图像展平为序列输入 Transformer 的计算要求是不切实际的。为了解决这个问题，ViT 提出将图像分割成固定大小的补丁，然后将每个补丁重塑为一个序列，以适应 Transformer 的计算要求。在这项工作中，我们使用  $3 \times 3$  卷积 (步幅 = 2) 进行下采样，并进行两次卷积操作，每次下采样四倍，逐渐获得输入图像的低分辨率高级特征。例如，HR-MSI 被下采样以获得与 LR-HSI 相同尺度的  $HR1 \in R^{H/4 \times W/4 \times C}$ 。然后，对 HR1 和 LR-HSI 进行相同的下采样操作，获得一对相同尺度的特征图， $HR2 \in R^{H/8 \times W/8 \times 2C}$  和  $LR \in R^{H/8 \times W/8 \times 2C}$ 。类推，我们可以获得  $n$  对相同尺寸的特征图。经过第  $n$  次下采样后的特征图可以表示为  $HRn \in R^{H/4n \times W/4n \times nC}$  和  $LR-n \in R^{H/4n \times W/4n \times nC}$ 。在逐渐的下采样过程中，提取了丰富的局部空间信息，随后， $HRn$  和  $LRn$  被输入到 MCT 中，以进一步对全局空间中的长距离依赖性进行建模。通过迭代，两个特征图的信息被充分提取和融合，实现了空间模

态和光谱模态的交互信息融合。如图 1所示：

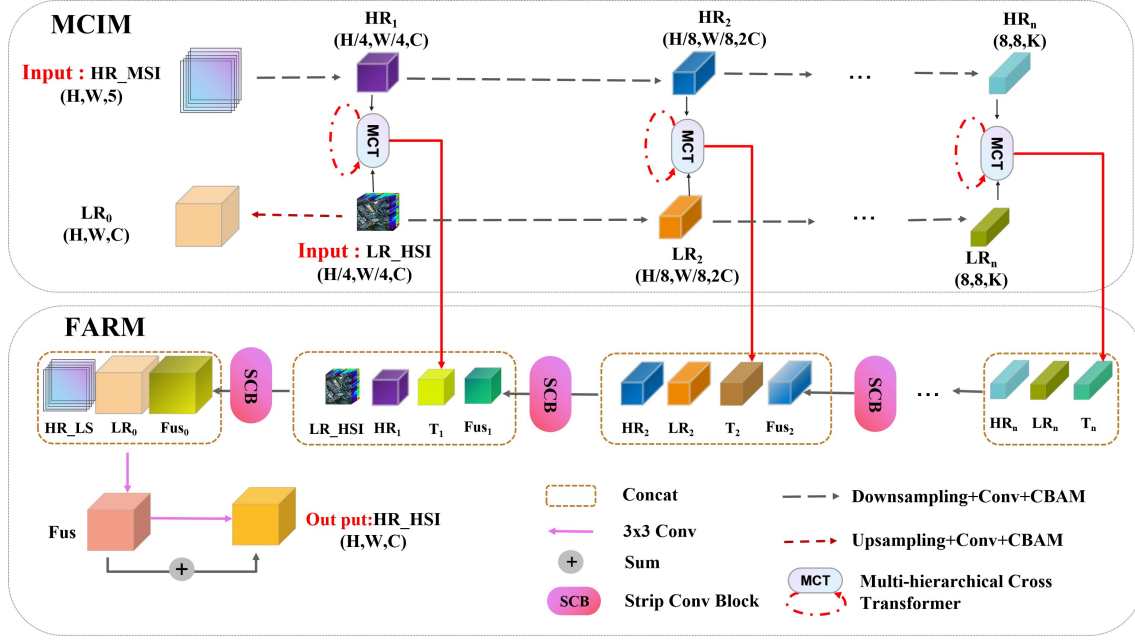


图 1. 整体结构图

### 3.2 多层次交互注意力

为实现光谱模态和空间模态之间的交叉信息融合，并对全局特征表示进行整体图像依赖建模，我们设计了一种多层次交互变压器（MCT）。MCT 的示意图如图 2所示：

MCT 采用双分支结构，包括线性投影、前馈网络（FFN）、层归一化等。值得一提的是，两个分支之间的信息交互通过多头融合注意力（MHFA）块实现。首先，对 LR-HSI 和 HR-MSI 特征图进行线性映射，然后通过 MHFA 在两个分支上对特征映射进行全局依赖建模，实现空间模态和光谱模态的交叉信息融合。FFN 包含一个两层多层感知机，隐藏层的扩展比率为  $r$ 。在每个块之前应用层归一化（LN），并在每个块之后应用残差快捷方式。可以将多个 MCT 连接到网络中，使两种模态之间的信息交换更充分。最终生成具有丰富光谱信息和丰富空间信息的特征图。图像序列化。假设给定两个本地特征图  $Feature1 \in R^H \times W \times C$ ,  $Feature2 \in R^H \times W \times C$ 。为了减轻计算负担并减少  $Feature1$  和  $Feature2$  中包含的冗余信息的不利影响，将线性投影应用于将通道维度从  $C$  压缩到  $d$ （在本文中， $d=64$  和  $128$ ）。MCT 期望以序列作为输入。因此，对输入特征图进行降维操作，得到两个  $d \times N$  ( $N=H \times W$ ) 序列  $x1$  和  $x2$ 。为了编码特征图的位置信息，引入了可学习的位置嵌入，将其与特征图  $x1$  和  $x2$  分别以直接相加的方式融合，然后对特征进行层归一化操作。上述过程可描述如下：

$$y1 = LN(LP(Feature1) + PE) \quad y2 = LN(LP(Feature2) + PE) \quad (1)$$

其中  $LP$  表示线性投影操作， $PE \in R^{d \times N}$  表示位置嵌入， $y1, y2 \in R^{d \times N}$  指的是特征嵌入。LN 表示层归一化。多头融合注意力。不同分支上的特征图包含不同的语义信息。为了对两个特征图进行整体图像依赖建模，并实现空间模态和光谱模态的交叉信息融合，引入了多头融合注意力（MHFA）。



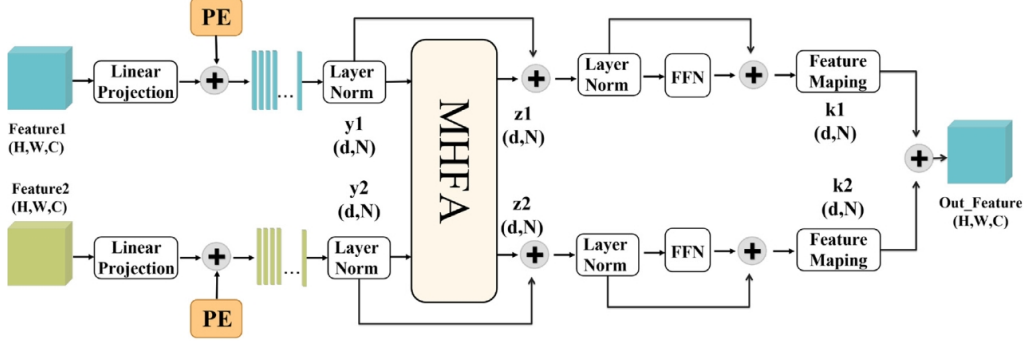


图 2. MCT 的结构图

### 3.3 特征聚合重建模块

经过 MCT 的处理, 具有丰富空间信息和光谱信息的两个输入被传递以获取一个输出, 充分整合了光谱信息和空间信息。此外, 我们在 MCT 的输入和输出特征之间建立了同一级别的跳跃连接。空间细节是否被准确重建影响着重建图像的质量, 而特征是否有效地融合利用则是学习多级特征表示的关键。因此, 我们设计了特征聚合重建模块 (FARM) 来将这三个特征图连接在一起, 并通过条形卷积块和级联上采样等操作逐渐恢复空间细节信息。条形卷积块。在条形卷积块中, 特征图经历了一次条形卷积操作, 然后是上采样和卷积操作。受中的 1D 转置卷积的启发, 我们在 FARM 中添加了条形卷积块。条形卷积块的结构如图 3 所示。对于输入特征图, 条形卷积块通过  $1 \times 1$  卷积将其输入到四个不同形状的条形卷积路径中。四个路径的输出特征图被连接起来。然后执行上采样操作和  $1 \times 1$  卷积以获得条形卷积块的最终输出。设  $w \in R^{2k+1}$  为大小为  $2k+1$  的条形卷积滤波器,  $D = (D_h, D_w)$  表示滤波器  $w$  的方向,  $H \in R^{H \times W \times C'}$  是条形卷积的结果。条形卷积可以定义如下:

$$HD[i,j] = F * w_D[i,j] = \sum_{t=-k}^k \chi[i + D_h t, j + D_w t] \cdot w[k - t] \quad (2)$$

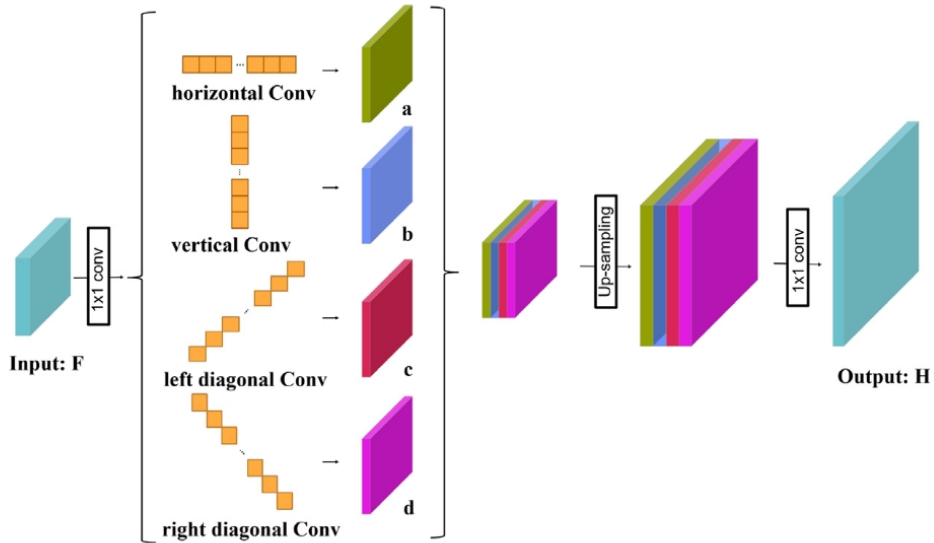


图 3. MCT 的结构图

## 4 复现细节

### 4.1 与已有开源代码对比

- 在原来文章提供的代码的基础上，完成了相关环境的部署，并成功复现了文章的实验结果。
- 在原来使用的数据集的基础上，新添加了四个数据集，并完成适配工作，让模型在新的数据集上得到验证的结果。
- 添加了新的评价指标，使评价体系更全面，验证实验结果更严谨。

### 4.2 实验环境搭建

1. 硬件环境 CPU: Intel(R) Xeon(R) CPU E5-2678 v3 @ 2.50GHz GPU: NVIDIA-SMI 515.105.01 Driver Version: 515.105.01 CUDA Version: 11.7 内存: 256GB
2. 软件环境操作系统: Ubuntu 20.04.3 LTS 编程语言: Python 3.9
3. 依赖项和库确保在搭建环境前安装以下依赖项: `bash Copy code pip install -r requirements.txt` PyTorch 1.9.0 NumPy 1.19.5 ...
4. 数据集使用的数据集为 [PaviaU、Botswana、Pavia、Washington、Urban]。此外在原文的基础上新添加的数据集为 [Indian、MUUFL\_HSI、Salinas\_corrected、Houston\_HSI]
5. 配置说明修改 `myconfig.yaml` 文件以适应你的实验设置。yaml Copy code 6. 安装说明运行以下命令安装依赖项: `bash Copy code pip install -r requirements.txt`
7. 运行实验确保所有依赖项安装完成后，运行以下命令启动实验:  
`bash Copy code python main.py` 和 `python test.py`
8. 结果实验结果将保存在 `figs/` 目录下。

### 4.3 新的数据集介绍

这里简要介绍一下这几个高光谱图像数据集：

1.Indian Pines: 描述: Indian Pines 是一个经典的高光谱图像数据集，用于遥感图像分析。它由印度 Purdue 大学收集，包含来自印度班加罗尔地区的高光谱图像。特点: 数据集包括 220 个波段，分辨率为 20 米。Indian Pines 主要用于农业和植被分类研究，是高光谱图像处理领域的基准数据集之一。

2.MUUFL Gulfport Hyperspectral Dataset (MUUFL\_HSI): 描述: MUUFL\_HSI 是由美国空军研究实验室 (Air Force Research Laboratory, AFRL) 提供的高光谱数据集。该数据集是在佛罗里达州 Gulfport 进行的。特点: MUUFL\_HSI 包括地面目标和背景，用于目标检测和高光谱图像分类。它的光谱范围广泛，可用于不同的应用领域。

3.Salinas Corrected: 描述: Salinas Corrected 是用于高光谱图像处理的数据集，由美国国家航空航天局 (NASA) 提供。数据集来自美国卡尔弗县 (California) 的 Salinas Valley。特点: 数据集包括 204 个波段，分辨率为 3.7 米。Salinas Corrected 主要用于农业和土地利用分类，以及高光谱影像处理算法的评估。

4.Houston Hyperspectral Image (Houston\_HSI): 描述: Houston\_HSI 是一个涉及城市区域的高光谱图像数据集, 由美国国家航空航天局 (NASA) 提供。特点: 数据集包括高光谱图像, 适用于城市区域的土地利用分类和环境监测。Houston\_HSI 的应用范围涵盖了城市规划和环境研究等多个领域。

#### 4.4 创新点

在该篇高光谱融合超分研究中, 引入结构相似性指数 (Structural Similarity Index, SSIM) 评价指标是我的创新点。相比传统的评价指标, 引入 SSIM 有以下几个创新之处:

结构感知评价: SSIM 是一种结构感知的图像质量评价指标, 不仅考虑了亮度和对比度的误差, 还包括了结构信息的相似性。传统评价指标 (如 PSNR 和 RMSE) 主要关注像素级的亮度误差, 而 SSIM 更加符合人眼对图像结构感知的方式。

全局和局部信息综合: SSIM 能够在全局和局部两个层面上评估图像质量。在高光谱图像处理中, 全局信息可能不足以完全描述图像的复杂结构。引入 SSIM 使得你的评价更加全面, 更好地捕捉到高光谱融合超分结果的细节和结构信息。

多角度质量度量: 传统的评价指标可能只关注一个方面的图像质量, 而 SSIM 通过分析图像的亮度、对比度和结构, 提供了一个更加全面的图像质量度量, 使你能够更全面地了解高光谱融合超分结果的优劣。

与人眼感知一致: SSIM 的设计目标是模拟人眼对图像的感知, 因此更符合人眼对图像质量的认知。通过引入 SSIM, 你的评价指标更加贴近人的主观感受, 从而更好地反映了高光谱图像融合超分的实际效果。

总体而言, 引入 SSIM 作为评价指标为该篇高光谱融合超分研究提供了一种更为全面、结构感知的质量度量方法, 使其研究更具创新性和实际应用的可行性。

## 5 实验结果分析

由于我们实验的数据集较多, 目前只分析在 Pavia Center 数据集上的结果, 其他数据集的结果均以文件的形式进行存储, 这边不再一一分析。在 Pavia Center 数据集上我们的方法获得了最低的 RMSE, 为 2.6848, 说明它相对于其他方法更接近于原始图像。这表明该方法在保留光谱信息的同时, 也更好地还原了空间细节。在 PSNR 方面: 我们的方法获得了最高的 PSNR, 为 39.5525。较高的 PSNR 表明 Ours 生成的图像更接近于原始图像, 相对于其他方法具有更好的图像质量。


ERGAS: 我们的方法的 ERGAS 为 3.0078, 是最低的。较低的 ERGAS 表明 Ours 在整体相对误差方面表现更好, 图像重建与原始图像的一致性更高。

SAM: 我们的方法的 SAM 为 3.6639, 是最低的。这意味着 Ours 在光谱保真度方面表现更好, 重建光谱更接近于原始光谱。


通过综合这些指标的分析, 我们的方法在 Pavia Center 数据集上取得了最佳的实验结果。它相对于其他方法在保留光谱信息、还原空间细节、整体相对误差和光谱保真度等方面都表现出色。因此, 可以得出我们的方法在高光谱与多光谱融合超分辨率中是一个有效的选择。在实际应用中, 研究人员和从业者可以考虑采用这种方法以提高图像质量和保真度。

表 1. Pavia Center 数据集上的比较实验结果


Method	Pavia Center			
	RMSE	PSNR	ERGAS	SAM
CNMF	13.9777	25.2221	11.4360	4.3635
CSU	5.0793	34.4197	5.6044	5.8472
SSE	4.1070	37.3270	4.8480	4.5984
MSDCNN	4.1687	35.7370	4.6840	5.4004
TFNet	4.2473	35.5686	4.8295	4.8437
ResTFNet	3.9258	36.2522	4.4449	4.6073
SSFCNN	4.7720	34.5569	5.7509	5.7962
ConSSFCNN	5.4998	33.3239	6.1594	6.1196
SSR-NET	3.6367	36.9164	4.1337	4.1005
Ours	2.6848	39.5525	3.0078	3.6639



(a) 低空间分辨率高光谱图



(b) MCT 输出的结果图



(c) 参考图片

图 4. 实验结果对比

## 6 总结与展望

通过复现 MCT 的模型, 使我对高光谱融合超分领域有了更多的了解, 同时, 通过调试代码, 添加新的数据集, 得到实验结果, 让我充分认识到不同的模型在不同的数据集上会有不一样的效果, 我们需要尽量的优化模型的可泛化性, 争取使模型能在不同的模型普遍得到一个较好的实验结果, 同时, 通过添加新的评价指标, 来从不同的角度去评价实验结果。从 SSIM 的角度出发, MCT 的模型的优越性就更加的明显, 在其他模型都没有达到 0.9 时, MCT 模型实验的结果就基本上稳定在 0.95 以上, 最好的结果可以达到 0.98 左右。这是我的创新之处, 充分挖掘 MCT 的更多数据集上的实验结果, 在更多评价指标下的对比。在后续的工作中, 我将继续优化模型, 甚至是在 MCT 的基础上提出新的模型结果, 优化 MCT 的不足之处, 让它可以通过轮次的迭代来进一步得到更好的结果。



## 参考文献

- [1] F. Luo, L. Zhang, B. Du, and L. Zhang. Dimensionality reduction with enhanced hybrid-graph discriminant learning for hyperspectral image classification. *IEEE Trans. Geosci. Remote Sens.*, 58(8):5336–5353, 2020.
- [2] D. Marinelli, F. Bovolo, and L. Bruzzone. A novel change detection method for multitemporal hyperspectral images based on binary hyperspectral change vectors. *IEEE Trans. Geosci. Remote Sens.*, 57(7):4913–4928, 2019.
- [3] L. Mou, P. Ghamisi, and X.X. Zhu. Deep recurrent neural networks for hyperspectral image classification. *IEEE Trans. Geosci. Remote Sens.*, 55(7):3639–3655, 2017.
- [4] W. Sun and Q. Du. Graph-regularized fast and robust principal component analysis for hyperspectral band selection. *IEEE Trans. Geosci. Remote Sens.*, 56(6):3185–3195, 2018.
- [5] Q. Wang, X. He, and X. Li. Locality and structure regularized low rank representation for hyperspectral image classification. *IEEE Trans. Geosci. Remote Sens.*, 57(2):911–923, 2018.
- [6] Q. Wang, J. Lin, and Y. Yuan. Salient band selection for hyperspectral image classification via manifold ranking. *IEEE Trans. Neural Netw. Learn. Syst.*, 27(6):1279–1289, 2016.
- [7] Q. Wang, Z. Yuan, Q. Du, and X. Li. Getnet: A general end-to-end 2-d cnn framework for hyperspectral image change detection. *IEEE Trans. Geosci. Remote Sens.*, 57(1):3–13, 2018.
- [8] Q. Wang, F. Zhang, and X. Li. Optimal clustering framework for hyperspectral band selection. *IEEE Trans. Geosci. Remote Sens.*, 56(10):5910–5922, 2018.
- [9] Y. Yuan, X. Zheng, and X. Lu. Discovering diverse subset for unsupervised hyperspectral band selection. *IEEE Trans. Image Process.*, 26(1):51–64, 2016.
- [10] L. Zhang, Y. Zhang, H. Yan, Y. Gao, and W. Wei. Salient object detection in hyperspectral imagery using multi-scale spectral-spatial gradient. *Neurocomputing*, 291:215–225, 2018.